PROJET FINAL • SCIENCE DES DONNÉES

SpaceX Falcon 9 : prédire l'atterrissage du premier étage

Harry Tegue Kemgne
Institut Mines-Télécom Business School
Octobre 2026



À VÉRIFIER

L'essentiel en trois chiffres

90

lancements Falcon 9 analysés

≈ 67 %

d'atterrissages réussis sur l'ensemble des lancements

≈ 83 %

de précision des modèles sur 18 lancements de test

Objectif : prédire si le premier étage atterrira, pour estimer le coût d'un lancement (62 M$ chez SpaceX contre 165 M$ et plus ailleurs).

Démarche : collecte via l'API SpaceX, EDA (SQL, graphiques, Folium, Dash), puis quatre classifieurs réglés par GridSearchCV.

Constat : le succès progresse avec l'expérience, et les quatre modèles se valent sur un jeu de test très réduit.

Pourquoi prédire un atterrissage ?

QUESTION

Peut-on prédire, avant le lancement, si le premier étage d'un Falcon 9 va atterrir avec succès ?

Contexte
SpaceX réutilise le premier étage : 62 M$ par lancement contre 165 M$ et plus chez les concurrents.

Enjeu
Savoir si l'étage sera récupéré permet d'estimer le coût d'un lancement et de bâtir une offre concurrente.

Données
Lancements Falcon 9 : site, orbite, charge utile, réutilisation, issue d'atterrissage.

Collecte et préparation des données

1

Collecte

Appels à l'API REST SpaceX (fusées, sites, charges utiles, cœurs), puis json_normalize.

2

Filtrage

Suppression des lancements Falcon 1 : seuls les Falcon 9 sont conservés.

3

Nettoyage

PayloadMass manquante remplacée par la moyenne ; LandingPad nul conservé.

4

Étiquetage

Class = 0 si l'atterrissage échoue ou n'est pas tenté, 1 sinon.

Résultat : un jeu de 90 lancements Falcon 9, prêt pour l'exploration et la modélisation.

EDA et analytique visuelle interactive

SQL (SQLite)
Dix requêtes : sites, charges utiles, boosters, issues d'atterrissage.

Matplotlib · Seaborn
Nuages de points, barres et courbe annuelle : vol, charge, orbite, site.

Folium
Cartes interactives : sites, marqueurs succès/échec, distances aux points proches.

Plotly Dash
Tableau de bord : filtre par site, plage de charge utile, camembert et nuage.

Analyse prédictive

1. **Cible**
   Y = colonne Class (1 = atterri)

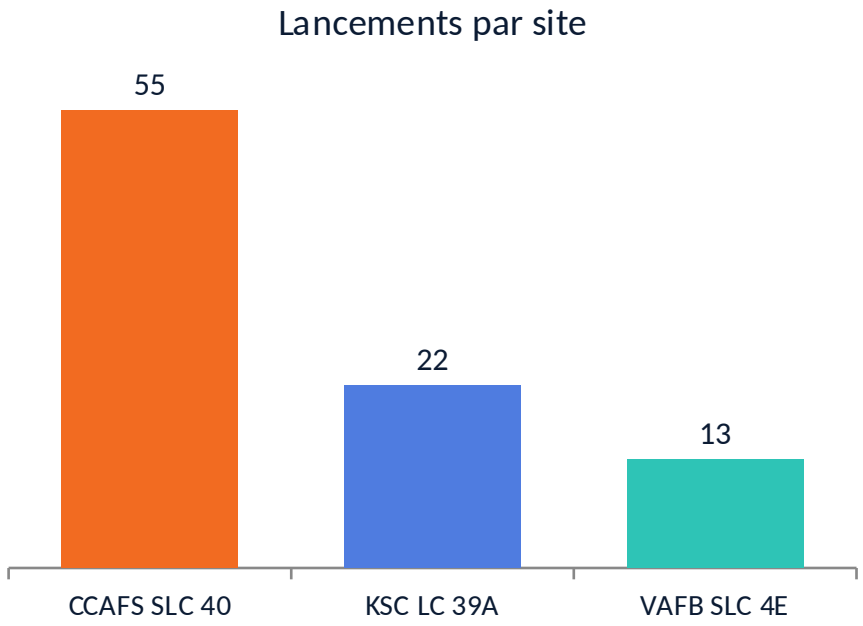
2. **Standardisation**
   StandardScaler sur X

3. **Séparation 80/20**
   random_state = 2 : 18 lancements de test

4. **Réglage**
   GridSearchCV, validation croisée à 10 plis

Modèle	Hyperparamètres testés
Régression logistique	C ∈ {0,01 ; 0,1 ; 1} · pénalité l2 · solveur lbfgs
SVM	noyau (linear, rbf, poly, sigmoid) · C et gamma sur 5 valeurs de 10^{-3} à 10^{3}
Arbre de décision	critère · splitter · profondeur 2 à 18 · min_samples_leaf/split
KNN	n_neighbors 1 à 10 · algorithme · p ∈ {1 ; 2}

Site de lancement et expérience



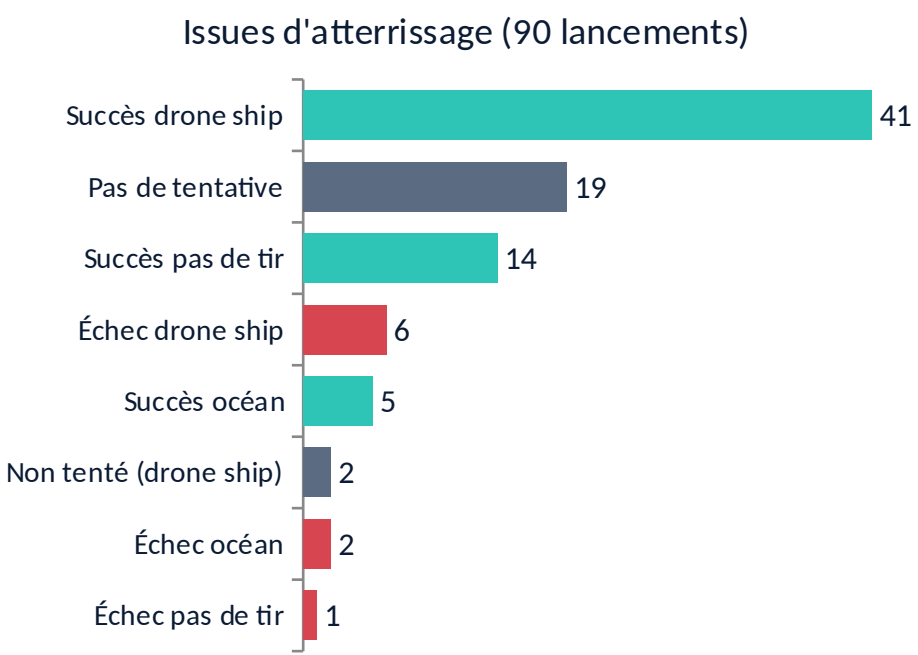
Expérience : sur chaque site, la part de succès augmente avec le numéro de vol.

Concentration : CCAFS SLC 40 porte 55 des 90 lancements (61 %).

Charge utile : aucun lancement de VAFB SLC 4E au-delà de 10 000 kg.

À VÉRIFIER

Issues d'atterrissage et facteurs de succès



60 succès sur 90 (≈ 67 %) ; le drone ship est la méthode de récupération la plus fréquente.

LEO : le succès suit le numéro de vol ; en GTO, aucun lien visible.

Charges lourdes : plus de succès en orbite polaire, LEO et ISS.

Tendance : taux de succès en hausse continue de 2013 à 2020.

À VÉRIFIER

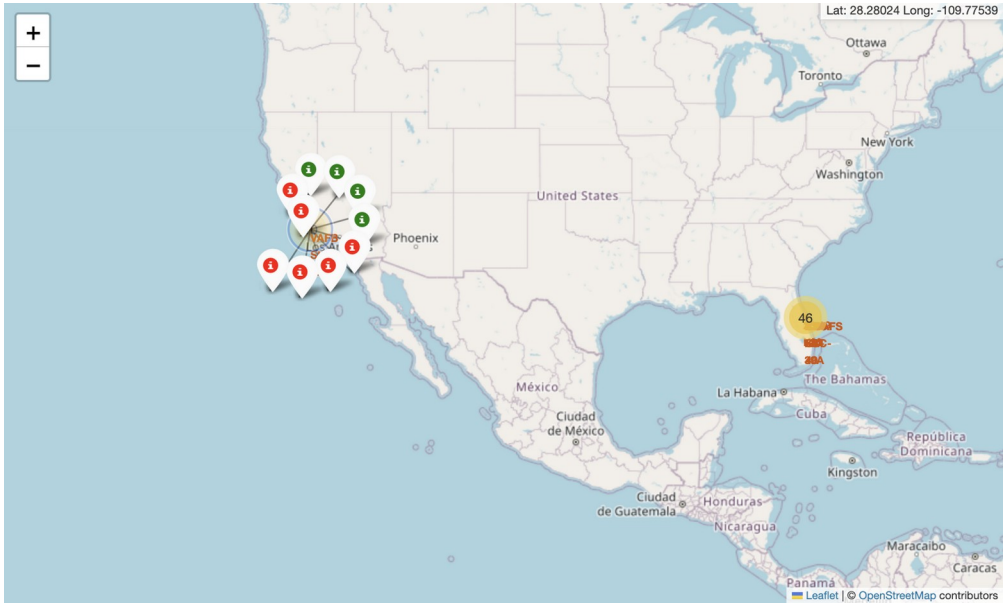
Ce que disent les requêtes

Question posée à la base	Résultat
Sites de lancement distincts	**4 sites**
Charge utile totale des missions NASA (CRS)	**45 596 kg**
Charge utile moyenne du booster F9 v1.1	**2 928 kg**
Premier atterrissage réussi sur pas de tir (ground pad)	**22 décembre 2015**
Résultats de mission	**100 succès, 1 échec en vol (101 missions)**
Boosters réussis sur drone ship, charge 4 000 à 6 000 kg	**F1022, F1026, F1021.2, F1031.2**

Table SPACEXTABLE (SQLite), interrogée avec la magie %%sql dans Jupyter.

À VÉRIFIER

Géographie des sites de lancement



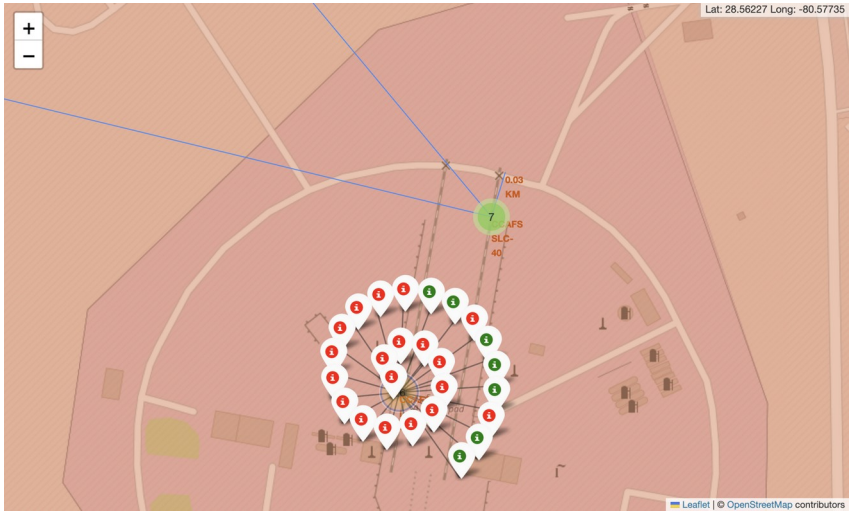
Latitude : Sites entre ≈ 28° et 35° de latitude nord : relativement proches de l'Équateur.

Littoral : Tous très proches de la côte (≈ 0,5 km pour CCAFS SLC-40) : trajectoires au-dessus de l'océan.

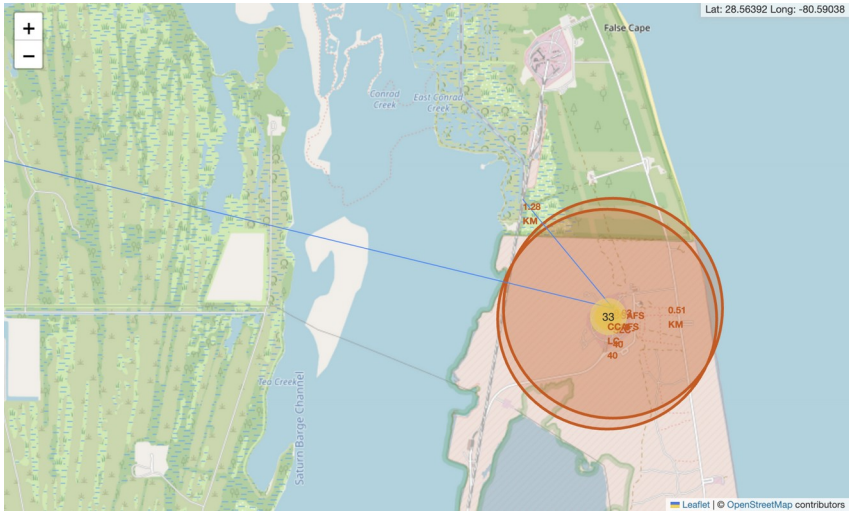
Logistique : Voies ferrées et routes à proximité pour acheminer le matériel.

Villes : Éloignées de plusieurs dizaines de km (≈ 23 km de Titusville).

Zoom sur CCAFS SLC-40



Lancements réussis (vert) et échoués (rouge), regroupés par cluster



Lignes de distance : littoral ≈ 0,5 km, autre point ≈ 1,3 km

À VÉRIFIER

Explorer les lancements en direct

Capture du tableau de bord

À insérer : menu déroulant, camembert, curseur et nuage de points

Menu déroulant : tous les sites ou un site précis.

Camembert : succès par site, ou succès contre échecs pour le site choisi.

Curseur : plage de charge utile de 0 à 10 000 kg.

Nuage de points : charge utile et succès, couleur par version de booster.

Lecture : KSC LC-39A affiche le meilleur taux de succès.

À VÉRIFIER

Performances des quatre modèles

Précision sur le jeu de test (18 lancements)

Régression logistique	≈ 83 %
SVM	≈ 83 %
Arbre de décision	≈ 83 %
KNN	≈ 83 %

Matrice de confusion · régression logistique



Les erreurs sont toutes des faux positifs : le modèle annonce un atterrissage qui n'a pas lieu.

APERÇUS

À VÉRIFIER

Ce que les chiffres ne disent pas seuls

Une précision très incertaine

15 réussites sur 18 : intervalle de confiance à 95 % d'environ 61 % à 94 %. Les écarts entre modèles ne sont pas significatifs.

Une fuite de données à corriger

La standardisation est ajustée avant la séparation. Un Pipeline scikit-learn l'ajusterait sur l'entraînement seul.

Un enjeu économique clair

Écart de prix annoncé d'au moins 103 M$ par lancement : chaque atterrissage prédit éclaire le coût marginal.

Ce que nous retenons

Le succès s'apprend

L'atterrissage réussit de plus en plus avec le numéro de vol, et dépend du site, de l'orbite et de la charge.

Des sites pensés pour le risque

Côte proche, villes éloignées, accès logistique : la géographie limite les dégâts d'un échec.

Des modèles comparables

Quatre classifieurs autour de 83 % sur le test ; la régression logistique se trompe surtout par excès d'optimisme.

Prochaines étapes

Plus de vols récents, Pipeline sans fuite, validation croisée imbriquée, ajout de variables de coût.

ANNEXE

Dépôt GitHub et livrables

Dépôt : https://github.com/<votre-compte>/<votre-depot>

1 · Collecte via l'API SpaceX

2 · Data wrangling et étiquetage

3 · EDA avec SQL

4 · EDA avec visualisation

5 · Carte interactive Folium

6 · Application Plotly Dash

7 · Prédiction par machine learning

Outils

Python · pandas · NumPy · scikit-learn

Matplotlib · Seaborn · Folium · Plotly Dash

SQLite · Jupyter · JupyterLite